# Challenge: Improve a Repository Migration Harness

Spezialisierung eines bestehenden Coding Agents für Repository-Level Code Migration

## Ziel

Entwickle einen schlanken, reproduzierbaren Harness, der einen bestehenden Coding Agent (beispielsweise Claude Code bzw. das Claude Agent SDK oder Codex ) für Migrationen ganzer Software-Repositories spezialisiert. Wir empfehlen z.B. Java → Python. Im Mittelpunkt steht nicht maximale Komplexität, sondern eine nachvollziehbare, datenbasierte Verbesserung des Agentenverhaltens.

## Aufgabe

Starte mit einer einfachen Baseline und bewerte ihre Ergebnisse auf mehreren kleinen Repositories. Analysiere anschließend typische Fehler, verbessere den Harness schrittweise und führe die Evaluation nach jeder relevanten Änderung erneut durch. Die Iterationen sollen erkennen lassen, welche Maßnahmen die Qualität tatsächlich beeinflussen.

Mögliche Stellschrauben sind präzisere Instructions, zusätzliche Tools, Repository-Analyse und Planung, strukturiertes Build- und Test-Feedback, Context Management sowie Completion Checks oder Backpressure auf Basis von deterministischen und nicht deterministischen Analysen. Du entscheidest selbst, welche Ansätze du priorisierst und wie du sie kombinierst.

## Datensatz und Evaluation

Als Ausgangspunkt kann RepoTransBench dienen. Alternativ kannst du vergleichbare kleine Open-Source-Repositories mit automatisierten Tests verwenden. Es ist ausdrücklich nicht Teil der Aufgabe, einen neuen Benchmark zu entwickeln. Wichtig sind reproduzierbare Bedingungen und eine aussagekräftige, für alle Iterationen vergleichbare Bewertung.

## Erwartete Abgabe

Deine Abgabe sollte kompakt dokumentiert sein und Folgendes enthalten:

- einen reproduzierbaren Harness in einer Programmiersprache deiner Wahl (vorzugsweise Python) mit klarer Anleitung zur Ausführung,
- eine einfache Baseline und mehrere begründete Verbesserungsiterationen,
- eine kurze Failure Analysis als Grundlage der jeweiligen Änderungen,
- eine knappe Auswertung der Qualitätsentwicklung, z. B. anhand von Test Pass Rate und Anteil erfolgreicher Migrationen,
- eine nachvollziehbare Zuordnung der beobachteten Effekte zu den Änderungen am Harness.

## Worauf wir achten

Wir bewerten vor allem die Klarheit des Vorgehens, die technische Qualität und Reproduzierbarkeit des Harness sowie die Sorgfalt, mit der du Ergebnisse und Fehlermuster analysierst und vorstellst. Eine fokussierte Lösung mit gut belegten Iterationen ist wertvoller als ein umfangreiches System ohne belastbare Evaluation.